The EAOS methodology defines a structured lifecycle for
Designing, deploying, and governing enterprise-grade AI systems

Project: Standard Framework Project

1.5 Human-in-the-Loop 구조

Phase: 1. Vision & Role 정의

[산출물 ID: 1.5 HITL Structure.docx]

WBS Task

1.5.1 HITL 3 가지 패턴 정의 (Pre-approval / On-risk / Post-review)
1.5.2 Decision Gate 구조 및 통과/거부/타임아웃 처리
1.5.3 Human Override 발동 조건 및 절차
1.5.4 Agent 별 HITL 적용 기준
1.5.5 Approval Gate 코드 구현 기준

문서 번호	1.5 HITL Structure.docx
버전	v1.0
작성일	2026
작성자	KY Song
분류	CONFIDENTIAL
적용 대상	Standard Framework 프로젝트 전체

Table of Contents

1. 개요 3
1.1 기존 산출물과의 관계 3
2. HITL 3 가지 패턴 4
2.1 P1 Pre-approval 4
2.2 P2 On-risk 5
2.3 P3 Post-review 6
3. Human Override 7
3.1 Override 발동 조건 7
3.2 Override 처리 절차 7
4. Agent 별 HITL 적용 기준 8
5. ApprovalGate 코드 구현 기준 9
5.1 DB 스키마 요구사항 9
5.2 Approval Gate 동작 규칙 9
5.3 SLA (응답 시간 기준) 10
6. 승인 (Approval) 11

1. 개요

Human-in-the-Loop(HITL)는 AI Agent 의 의사결정 과정에 인간이 직접 개입하여 검토·승인함으로써 책임성과 안전성을 확보하는 구조다. 본 문서는 기존 Authority Model(1.4)과 R&R Matrix(1.3)에서 'Human 승인 필수'로 정의된 항목들의 구체적인 동작 방식을 정의한다.

> *Authority Model 이 '어디서 승인받는지'를 정의했다면, HITL 구조는 '어떻게 승인받는지'를 정의한다. Phase 3 ApprovalGate 코드 구현의 직접 기준이 된다.*

1.1 기존 산출물과의 관계

산출물	HITL 관련 정의 범위	1.5 에서 추가 정의
1.3 R&R Matrix	어떤 Activity 에 Human 승인 필요	승인 방식 및 처리 흐름 상세화
1.4 Authority Model	Agent 별 Human Gate 위치	Gate 통과/거부/타임아웃 동작 정의
1.6 Charter 제 5 조	Human Override 원칙 선언	Override 발동 조건 및 절차 구체화
governance.json	human_checkpoint: on_risk 정의 (Phase 1 완료 후 생성 예정)	3 가지 패턴 분류 및 코드 구현 기준

2. HITL 3 가지 패턴

본 프로젝트의 모든 Human 개입은 다음 3 가지 패턴 중 하나로 분류된다.

패턴	명칭	정의	적용 시점	적용 Agent
P1	**Pre-approval**	AI 실행 전 Human 이 먼저 승인해야 진행 가능	**실행 전**	Orch, Back-A, Evol-A
P2	**On-risk**	실행 중 Risk 기준 초과 시 Human 에게 즉시 에스컬레이션	**실행 중 이상 감지**	Orch, Monitor-A, Back-A
P3	**Post-review**	AI 실행 완료 후 Human 이 결과를 검토하고 최종 확정	**실행 후 산출물 확정**	UIUX-A, Front-A, Test-A

2.1 P1 Pre-approval

AI 가 실행하기 전에 Human 이 반드시 승인해야 한다. 미승인 시 Agent 는 대기 상태로 유지된다.

적용 대상

Agent	적용 상황	승인 주체
Orch	Decision Gate 진입 시	Business Owner 또는 AI Architect
Back-A	DB 스키마 변경 / 외부 API 연동	AI Architect + Back-H (Backend Developer)
Evol-A	Context 수정 제안 제출 시	Governance Board
Orch (Level 변경)	Authority Level 변경 요청 시	Governance Board

처리 흐름

① **Agent 실행 요청** Agent 가 작업 시작 전 ApprovalGate 호출

② **승인 요청 생성** approval_requests 테이블 INSERT + 담당자 알림 발송

③ **Human 검토** 승인자가 요청 내용 확인 (SLA: 업무일 기준 24 시간)

✓ **승인** Agent 실행 재개 + audit_logs APPROVED 기록

✕ **거부** Agent 실행 취소 + 거부 사유 audit_logs 기록 + 요청자 알림

□ **타임아웃 (24h 초과)** 자동 에스컬레이션 → 상위 승인자에게 재전달 + Orch 알림

2.2 P2 On-risk

실행 중 Risk Threshold 초과 또는 이상 감지 시 즉시 실행을 중단하고 Human 에게 에스컬레이션한다.

트리거 조건

트리거	감지 주체	즉각 조치
Risk Level CRITICAL 감지	Orch / Monitor-A	즉시 실행 중단 → Business Owner 알림 → 긴급 대응
Risk Level HIGH + 미승인 실행	Orch	실행 차단 → Human 승인 게이트 재진입
KPI Threshold 초과	Monitor-A	Incident 알림 → Orch 에스컬레이션 → AI Architect 검토
Drift 감지	Monitor-A	알림 발송 → Orch → Evol-A 제안 프로세스 시작
Scope 초과 시도	Orch	즉시 차단 → 예외 승인 절차 → audit_logs 기록
Audit Log 실패	Back-A / Orch	배포 차단 → 로그 구현 의무 → 재심사

처리 흐름

① **이상 감지** Monitor-A 또는 Agent 자체 Risk 체크에서 Threshold 초과

② **즉시 실행 중단** 진행 중인 작업 안전하게 중단 + 중단 지점 snapshot 저장

③ **Orch 에스컬레이션** Orchestrator 에 사유 + 컨텍스트 전달

④ **Human 알림** 담당 Human 에게 Incident 내용 즉시 통보 (SLA: 1 시간)

✅ **Human 조치 후 재개** Human 이 원인 확인 및 조치 완료 → 재개 승인 → Agent 재시작

🔄 **미해결 시 롤백** Human 조치 불가 판단 시 이전 안정 상태로 롤백

2.3 P3 Post-review

AI 가 작업을 완료한 후 Human 이 결과를 검토하고 최종 확정한다. 미확정 산출물은 배포/적용 불가.

적용 대상

Agent	검토 대상 산출물	검토 주체
UIUX-A	Persona 분석 결과 / Scenario 초안	UX Designer (UIUX-H)
Front-A	React 컴포넌트 코드	Frontend Developer (Front-H)
Back-A	API / Agent 코드	Backend Developer (Back-H)
Test-A	Evaluation Report / KPI 결과	QA Engineer (Test-H)
Evol-A	Context 수정 제안서	AI Architect + Governance Board

처리 흐름

① **Agent 작업 완료** 산출물 생성 완료 + trajectory_logs 기록

② **검토 요청 생성** review_requests 테이블 INSERT + 검토자 알림

③ **Human 검토** 검토자가 산출물 확인 (SLA: 업무일 기준 48 시간)

✅ **확정 (Confirm)** 산출물 상태 CONFIRMED → 배포/적용 가능 상태로 전환

🔄 **수정 요청 (Revise)** 수정 사항 명시 → Agent 재작업 → 검토 재시작

❌ **거부 (Reject)** 산출물 폐기 + 사유 기록 + Orch 알림 + 재설계 여부 결정

⏱ **타임아웃 (48h 초과)** 자동 리마인더 → 추가 24h 후에도 미검토 시 PM 에스컬레이션

3. Human Override

Human Override 는 어떠한 상황에서도 인간이 AI Agent 의 실행을 즉시 중단하거나 변경할 수 있는 최우선 권한이다. AI 시스템은 Override 를 방해하거나 우회할 수 없다.

> ⚠ **Human Override 는 어떠한 자동화 로직도 막을 수 없다. Override 발동 시 모든 Agent 는 즉시 응답해야 한다.**

3.1 Override 발동 조건

발동 조건	발동 주체	즉각 효과
AI 출력이 명백히 잘못된 경우	모든 Human 참여자	해당 Agent 즉시 중단 + 결과 폐기
예상치 못한 부작용 발생	PM / AI Architect	관련 Agent 전체 중단 + Rollback
보안 위협 감지	Compliance Officer	전체 시스템 격리 + 보안 감사
규제 위반 가능성 감지	Compliance Officer / PM	즉시 중단 + 법무 검토 요청
Human 의 직관적 판단	모든 Human 참여자	즉시 중단 (사유 설명 불필요)

3.2 Override 처리 절차

① **Override 발동** Human 이 Override 명령 실행 (UI 버튼 또는 API 직접 호출)

② **전체 Agent 즉시 중단** Orchestrator 가 모든 실행 중인 Agent 에 STOP 신호 전파 (3 초 내)

③ **상태 Snapshot 저장** 중단 시점의 Context, 실행 상태, 입출력 데이터 보존

④ **audit_logs 기록** OVERRIDE 이벤트 기록: 발동자, 시각, 사유, 영향 Agent 목록

⑤ **Human 조치** PM / Architect 가 원인 분석 및 조치 방향 결정

⑥ **재개 또는 롤백 결정** 조치 완료 후 재개 승인 OR 이전 안정 상태로 롤백

⑦ **Governance 보고** Override 발생 사실을 24h 내 Governance Board 에 보고

4. Agent 별 HITL 적용 기준

Agent	P1 Pre	P2 On-risk	P3 Post	비고
★ **Orch**	✓✓	✓✓	—	모든 Decision Gate = P1. Risk 감지 = P2
Monitor-A	—	✓✓	—	탐지 전용. P2 트리거 후 Orch 에 전달
Back-A	✓✓	✓✓	✓✓	DB 변경 = P1. 실행 중 = P2. 코드 = P3. P2 없음: Context 제안 단계는 실행 없음 — 이상 시 Orch P2 대리 처리
Front-A	—	—	✓✓	코드 생성 후 Human 검수 (P3)
Test-A	—	✓✓	✓✓	KPI 이상 = P2. Evaluation Report = P3
Evol-A	✓✓	—	✓✓	Context 제안 제출 = P1. 제안서 검토 = P3
UIUX-A	—	—	✓✓	산출물 확정은 항상 P3 (Human 전담)

5. ApprovalGate 코드 구현 기준

Phase 3 코드 구현 시 Cursor AI 가 참조하는 ApprovalGate 의 구현 표준이다.

5.1 DB 스키마 요구사항

테이블	패턴	필수 컬럼
approval_requests	**P1**	id, agent_code, action_type, payload, status(PENDING/APPROVED/REJECTED), requested_by, approver, requested_at, resolved_at, rejection_reason
review_requests	**P3**	id, agent_code, artifact_type, artifact_id, status(PENDING/CONFIRMED/REVISED/REJECTED), reviewer, created_at, reviewed_at, revision_note
override_logs	**P2 / Override**	id, triggered_by, trigger_reason, affected_agents, snapshot_ref, action_taken, reported_at, governance_notified

5.2 Approval Gate 동작 규칙

상황	처리 방식	audit_logs 기록
승인 (APPROVED)	Agent 실행 재개 + 결과 정상 처리	status=APPROVED, approver, approved_at
거부 (REJECTED)	Agent 실행 취소 + 거부 사유 저장 + 알림	status=REJECTED, rejection_reason, rejected_by
타임아웃 P1 (24h)	상위 승인자 자동 에스컬레이션 + Orch 알림	status=ESCALATED, escalated_at, original_approver
타임아웃 P3 (48h)	리마인더 발송 → +24h 후 PM 에스컬레이션	status=REMINDER_SENT, reminder_sent_at
Override 발동	즉시 중단 + Snapshot 저장 + 전파	event=OVERRIDE, triggered_by, affected_agents
Audit Log 실패	Agent 실행 차단 + 에러 알림 + 재시도 불가	status=BLOCKED, reason=AUDIT_LOG_FAILURE

5.3 SLA (응답 시간 기준)

패턴	SLA	타임아웃 조치	에스컬레이션 대상
P1 Pre-approval	**업무일 24 시간**	상위 승인자 자동 전달	AI Architect → PM → Governance Board
P2 On-risk	**1 시간**	Orch 자동 에스컬레이션	즉시 PM / Business Owner
P3 Post-review	**업무일 48 시간**	리마인더 → PM 알림	Front-H/Back-H → AI Architect → PM
Override 응답	**3 초 (자동)**	시스템 강제 중단	해당 없음 (자동 처리)

6. 승인 (Approval)

구분	내용	서명	날짜
작성자			
검토자 (AI Architect)			
승인자 (Business Owner)			
버전	v1.0		